

Factores determinantes de la adopción de vehículos eléctricos a nivel nacional

Juan Manuel Vera Osorio
Ingeniería de Sistemas, Universidad de Antioquia
Medellín, Antioquia, Colombia

Abstract—Este trabajo presenta un análisis exploratorio de datos (EDA) sobre los factores que inciden en la adopción de vehículos eléctricos (EV) a nivel nacional. Se utilizó el conjunto de datos `ev_vs_petrol_dataset_v3` [3] que integra información de 20 países entre 2010 y 2025, con tres segmentos vehiculares. La metodología abarcó cuatro etapas: (1) análisis exploratorio univariado, bivariado y multivariado; (2) gestión de multicolinealidad; (3) detección de datos atípicos mediante métodos gráficos, estadísticos (IQR, Z-score) y de aprendizaje automático (Isolation Forest, LOF); y (4) transformación logarítmica y escalamiento con `StandardScaler`. Los resultados indican que la regulación ambiental (`emission_regulation_score`, $r \approx 0.663$) es el predictor más correlacionado con la participación de mercado EV, seguido del PIB per cápita ($r \approx 0.46$). Se identificó un punto de inflexión en la adopción global entre 2018 y 2020, y se evidenció heterogeneidad estructural entre regiones y segmentos. Los valores atípicos corresponden a observaciones genuinas y se conservaron deliberadamente.

Index Terms—vehículos eléctricos, análisis exploratorio de datos, detección de outliers, regulación ambiental, ciencia de datos.

I. INTRODUCCIÓN

LA transición hacia la movilidad eléctrica representa uno de los cambios tecnológicos más significativos del sector transporte en las últimas décadas. La adopción de vehículos eléctricos ha crecido de forma acelerada a nivel global, impulsada por la convergencia de factores económicos, regulatorios, energéticos y de infraestructura que varían considerablemente entre naciones. Comprender qué factores tienen mayor poder explicativo sobre la participación de mercado de los EV resulta fundamental tanto para la formulación de política pública como para la investigación académica en movilidad sostenible.

A diferencia de estudios cualitativos o de caso, el enfoque cuantitativo basado en datos longitudinales comparativos permite identificar patrones sistemáticos que trascienden contextos nacionales particulares. Sierzechula et al. señalan que la adopción de EV es un fenómeno multifactorial en el que subsidios, precios de combustibles y disponibilidad de infraestructura de carga interactúan de manera compleja [1]. En la misma línea, Noel et al. destacan que el entorno regulatorio es un predictor robusto de la tasa de electrificación del parque automotor [2].

El presente trabajo aborda la pregunta: ¿qué factores afectan la adopción de vehículos eléctricos en una nación? Para responderla se aplica un ciclo analítico completo sobre el dataset `ev_vs_petrol_dataset_v3` [3], cubriendo el análisis exploratorio, la gestión de multicolinealidad, la detección de outliers y el preprocesamiento orientado a modelado, con el objetivo de identificar los predictores más relevantes y construir una base de calidad para análisis futuros.

II. METODOLOGÍA

A. Fuente y características del dataset

Se utilizó el conjunto de datos `ev_vs_petrol_dataset_v3`, publicado en Kaggle por Aryan Mishra (2024) [3] bajo licencia abierta. El dataset contiene 1 200 filas distribuidas en tres segmentos —*commercial*, *mass_market* y *premium*— para 20 países entre 2010 y 2025, con 22 variables. Para evitar triplicar artificialmente las variables macroeconómicas —idénticas para los tres segmentos de un mismo país-año—, el análisis se realizó en dos niveles: el dataset completo (1 200 filas) para variables de segmento vehicular, y un dataset agregado por país-año (400 filas) para variables macroeconómicas e indicadores de infraestructura.

La variable dependiente seleccionada fue `ev_market_share`, por ser la medida de adopción más comparable entre países. Los predictores candidatos incluyeron: `gdp_per_capita`, `ev_subsidy_usd`, `fuel_price_usd_per_liter`, `electricity_price_usd_per_kwh`, `charging_stations`, `fast_chargers_share`, `emission_regulation_score` y `urban_population_percent`.

B. Análisis exploratorio de datos

El EDA se organizó en cuatro niveles. En el análisis univariado se examinaron las distribuciones temporales mediante boxplots por año, histogramas y gráficos de tendencia, identificando un crecimiento acelerado en la adopción a partir de 2018–2020. El análisis bivariado incluyó diagramas de dispersión de cada predictor frente a `ev_market_share`, coloreados por año, para detectar relaciones lineales, no lineales o dependientes del tiempo.

El análisis multivariado utilizó una matriz de correlaciones de Pearson combinada con nubes de dispersión entre todos los pares de predictores. Se aplicó el umbral $|r| \geq 0.6$ para identificar pares redundantes e informar la selección del conjunto final de variables. Finalmente, se analizaron diferencias estructurales por región geográfica y segmento vehicular mediante boxplots y evoluciones temporales.

C. Detección y tratamiento de datos atípicos

Se emplearon cuatro métodos complementarios: (1) boxplots por variable para identificación visual fuera del rango IQR; (2) regla IQR con límites $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$; (3) Z-score con umbral $|z| > 3$, empleado como complemento dado que es más sensible a distribuciones asimétricas; y (4) Isolation Forest y LOF para detectar outliers multivariados —observaciones atípicas en la combinación conjunta de variables [5], [6]. En todos los casos se verificó si los valores extremos correspondían a errores de medición o a variación real del fenómeno.

D. Preprocesamiento: transformación y escalamiento

Antes del preprocesamiento se verificó la integridad del dataset: ausencia de valores nulos, infinitos y filas duplicadas. Dado que no se presentaron valores faltantes, la etapa de imputación se omitió documentadamente. El análisis de asimetría sobre los predictores finales identificó variables con distribución fuertemente asimétrica ($|\text{skew}| \geq 1$), a las cuales se les aplicó la transformación $\log(x + 1)$ para reducir el efecto de los valores extremos. El escalamiento se realizó con StandardScaler ($\mu = 0, \sigma = 1$) sobre el conjunto depurado de predictores finales, eligiéndolo sobre MinMaxScaler por su mayor robustez ante colas largas.

E. Herramientas utilizadas

Todo el análisis fue implementado en Python 3 sobre Google Colab, con las librerías pandas y NumPy para manipulación de datos [8], matplotlib y seaborn para visualización [7], scipy.stats para cálculos estadísticos, y scikit-learn para Isolation Forest, LOF y StandardScaler [4]. El proyecto se documentó en un notebook de Jupyter con comentarios explicativos en cada etapa.

III. RESULTADOS Y ANÁLISIS

A. Descripción del dataset

El dataset integra 22 variables para 20 países en 16 años, con tres segmentos por país-año. La Tabla I resume las principales estadísticas descriptivas de las variables seleccionadas para el análisis a nivel país-año ($n = 400$).

TABLA I ESTADÍSTICAS DESCRIPTIVAS DE LAS VARIABLES CLAVE ($N = 400$)

Variable	Media	Desv. Est.	Skewness
ev_market_share (%)	18.4	20.1	1.87
gdp_per_capita (KUSD)	38.2	22.4	0.62
ev_subsidy_usd (KUSD)	3.45	3.20	0.71
charging_stations (miles)	28.4	68.9	10.2
emission_reg_score	6.20	2.10	0.14
fast_chargers_share (%)	22.3	12.4	0.83
electricity_price (USD/kWh)	0.19	0.09	0.41
urban_population (%)	74.5	13.2	-0.53

B. Tendencia temporal y heterogeneidad entre países

El análisis univariado reveló un crecimiento no lineal en la adopción promedio de EV: moderado entre 2010 y 2017, con una aceleración marcada a partir de 2018–2020 que

sugiere un punto de inflexión en la transición tecnológica, posiblemente asociado a la maduración de la tecnología de baterías y al endurecimiento simultáneo de regulaciones de emisiones en múltiples jurisdicciones.

Los boxplots por año evidenciaron un aumento progresivo de la dispersión entre países: hasta 2016 la mayoría presentaba niveles bajos y homogéneos, mientras que en los años posteriores la variabilidad se incrementó considerablemente. Esto indica que la transición operó a múltiples velocidades: algunos países consolidaron un liderazgo temprano —particularmente del norte de Europa— mientras otros avanzan de forma más gradual. La infraestructura de carga y la regulación ambiental exhibieron incrementos sostenidos en el mismo período, acompañando el crecimiento del mercado.

C. Análisis de multicolinealidad y selección de predictores

La matriz de correlaciones entre los ocho predictores candidatos identificó tres pares con $|r| \geq 0.6$. La Tabla II resume los pares detectados y las decisiones adoptadas. El par de mayor correlación (fuel_price ↔ emission_regulation_score, $r = 0.816$) evidenció redundancia clara, dado que ambas variables capturan aspectos del entorno de costos y presión regulatoria. En consecuencia, fuel_price fue eliminada, conservando emission_regulation_score por su mayor interpretabilidad directa.

TABLA II PARES CON ALTA CORRELACIÓN Y DECISIONES ADOPTADAS

Par de variables	r	Decisión
fuel_price ↔ emission_reg_score	0.816	Eliminar fuel_price
gdp_per_capita ↔ emission_reg_score	0.663	Conservar ambas
fuel_price ↔ electricity_price	0.647	Resuelto por (1)

El conjunto final de siete predictores conservados fue: gdp_per_capita, ev_subsidy_usd, emission_regulation_score, urban_population_percent, fast_chargers_share, charging_stations y electricity_price_usd_per_kwh.

D. Relevancia de los predictores sobre la adopción

Una vez depurado el conjunto de predictores, se evaluó la correlación individual de cada uno con ev_market_share. La Tabla III presenta los resultados en orden de magnitud absoluta.

TABLA III CORRELACIÓN DE PEARSON DE LOS PREDICTORES CON EV_MARKET_SHARE

Variable	r	Interpretación
emission_reg_score	+0.663	Predictor más correlacionado
charging_stations (log)	+0.589	Infraestructura acompaña la transición
gdp_per_capita	+0.463	Nivel de ingreso facilitador
fast_chargers_share	+0.412	Calidad de red de carga
urban_population	+0.318	Urbanización facilita la adopción
electricity_price	+0.214	Relación positiva débil
ev_subsidy_usd	-0.062	Paradoja: países rezagados subsidian más

El resultado más destacado es la correlación negativa de `ev_subsidy_usd` ($r \approx -0.06$). Esta paradoja no implica que el subsidio sea perjudicial, sino que refleja una causalidad inversa: los países con menor adopción tienden a ofrecer más subsidios como mecanismo de incentivo en etapas tempranas del mercado. Verificar esta hipótesis requeriría modelos con rezagos temporales.

E. Heterogeneidad por región y segmento

El análisis bivariado categórico reveló diferencias estructurales relevantes. Europa lidera la adopción con una mediana de `ev_market_share` notablemente superior al resto de regiones, seguida por APAC con un crecimiento acelerado desde 2018. América del Norte y LATAM presentan niveles significativamente más bajos, con pendientes de crecimiento más moderadas.

Por segmento vehicular, premium muestra la adopción más alta de forma consistente, confirmando que los EV penetraron primero en mercados de alto ingreso antes de masificarse. El segmento commercial registra la adopción más baja, explicable por las mayores exigencias de autonomía y logística de carga para flotas. Estas variables categóricas constituyen efectos agrupadores que deberán controlarse como efectos fijos en modelos futuros.

F. Detección y tratamiento de datos atípicos

Los cuatro métodos de detección fueron convergentes en identificar los mismos grupos de observaciones como atípicas. La Tabla IV resume los resultados por método estadístico.

TABLA IV RESUMEN DE DETECCIÓN DE OUTLIERS (N = 400)			
Variable	IQR (N)	IQR (%)	Z-score (N)
charging_stations	39	9.8%	5
ev_market_share	28	7.0%	8
ev_subsidy_usd	21	5.3%	3
gdp_per_capita	8	2.0%	2
emission_reg_score	0	0.0%	0
electricity_price	4	1.0%	0

La divergencia entre IQR y Z-score es mayor en variables con distribución muy asimétrica —especialmente `charging_stations`—, lo que anticipaba la necesidad de transformación logarítmica. La verificación conceptual de los casos extremos confirmó que todos corresponden a variación real: los valores altos de `charging_stations` pertenecen a economías de gran escala (China, EE.UU.), y los valores altos de `ev_market_share` a países nórdicos con políticas de electrificación muy avanzadas. En consecuencia, se decidió conservar todos los registros, evitando pérdida de información sobre los casos más avanzados en la transición.

G. Pipeline de preprocesamiento

La verificación inicial confirmó la ausencia de valores nulos, infinitos y filas duplicadas. El análisis de asimetría identificó `charging_stations` ($skew \approx 10.2$) y `co2_emissions_transport_mt` ($skew \approx 3.7$) como candidatas a

transformación `log1p`, que redujo su asimetría a valores próximos a cero. La Tabla V resume las decisiones del pipeline.

TABLA V RESUMEN DEL PIPELINE DE PREPROCESAMIENTO	
Etapas	Decisión
Verificación de nulos	Sin imputación — dataset sin valores faltantes
Outliers	Se conservan — representan variación real
Transformación <code>log1p</code>	<code>charging_stations</code> y <code>co2_emissions_transport_mt</code>
Variable objetivo	Sin transformar — decisión de modelado
Escalamiento	StandardScaler sobre 7 predictores finales

IV. CONCLUSIONES

Este trabajo presentó un ciclo analítico completo sobre los factores determinantes de la adopción de vehículos eléctricos. Los hallazgos se sintetizan en cuatro dimensiones.

En primer lugar, la adopción global de EV muestra una aceleración clara a partir de 2018–2020, con una brecha creciente entre países líderes y rezagados. Este punto de inflexión coincide con el endurecimiento de regulaciones de emisiones en Europa y con la reducción de costos de baterías a nivel global, lo que sugiere que ambos factores operaron de forma sinérgica.

En segundo lugar, el entorno regulatorio es el predictor más correlacionado con la adopción ($r \approx 0.663$), lo que indica que las políticas de presión normativa —estándares de emisiones, restricciones a vehículos de combustión— constituyen el factor más determinante en la tasa de electrificación. El PIB per cápita actúa como condición facilitadora moderada ($r \approx 0.46$), mientras que los subsidios presentan una paradoja estadística que requiere análisis causal con rezagos temporales.

En tercer lugar, los outliers detectados son observaciones genuinas que aportan información crítica sobre los casos más avanzados en la transición. Eliminarlos habría sesgado el análisis hacia el comportamiento de economías en etapas intermedias, perdiendo precisamente los casos más informativos para la comprensión del fenómeno.

En cuarto lugar, el pipeline de preprocesamiento resultante —transformación `log1p` seguida de StandardScaler sobre el conjunto depurado de siete predictores— constituye una base válida para la construcción de modelos predictivos futuros.

Como limitaciones, la granularidad país-año impide analizar el comportamiento individual del consumidor ni efectos de corto plazo. La colinealidad residual entre `gdp_per_capita` y `emission_regulation_score` ($r = 0.663$) requerirá monitoreo en modelos de regresión. Asimismo, factores culturales y de disponibilidad de modelos específicos no están capturados en el dataset.

Como trabajo futuro se propone construir un modelo de regresión múltiple con los siete predictores preprocesados; aplicar efectos fijos por país o región para controlar heterogeneidad estructural no observada; explorar modelos con rezagos temporales para la paradoja del subsidio; y

segmentar el análisis por etapa de madurez del mercado (líderes vs. emergentes en EV).

RECONOCIMIENTOS

El autor agradece a la profesora María Bernarda Salazar Sánchez, Ph.D., por la orientación metodológica y los aportes críticos durante el desarrollo del proyecto de aula en el curso Fundamentos de Ciencia de Datos, Universidad de Antioquia.

. REFERENCIAS

- [1] W. Sierzechula, S. Bakker, K. Maat, y B. van Wee, "The influence of financial incentives and other socio-economic factors on electric vehicle adoption," *Energy Policy*, vol. 68, pp. 183–194, 2014, doi: 10.1016/j.enpol.2014.01.043.
- [2] L. Noel, G. Zarazua de Rubens, J. Kester, y B. K. Sovacool, "Beyond emissions and economics: Rethinking the co-benefits of electric vehicles (EVs) and vehicle-to-grid (V2G)," *Transport Policy*, vol. 71, pp. 140–151, 2019, doi: 10.1016/j.tranpol.2018.12.014.
- [3] A. Mishra, "Will EVs replace petrol cars? [Dataset]," Kaggle, 2024. [Online]. Available: <https://www.kaggle.com/datasets/aryanmdev/will-evs-replace-petrol-cars/>
- [4] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://scikit-learn.org/>
- [5] M. M. Breunig, H.-P. Kriegel, R. T. Ng, y J. Sander, "LOF: Identifying density-based local outliers," en *Proc. ACM SIGMOD*, 2000, pp. 93–104, doi: 10.1145/342009.335388.
- [6] F. T. Liu, K. M. Ting, y Z.-H. Zhou, "Isolation forest," en *Proc. IEEE ICDM*, 2008, pp. 413–422, doi: 10.1109/ICDM.2008.17.
- [7] M. L. Waskom, "Seaborn: Statistical data visualization," *J. Open Source Softw.*, vol. 6, no. 60, Art. no. 3021, 2021, doi: 10.21105/joss.03021.
- [8] W. McKinney, *Python for Data Analysis*, 3ra ed. Sebastopol, CA, USA: O'Reilly Media, 2022.